


■ 权值向量为二维的情况

- ✓ 大步长($\mu = 0.1$): 收敛速度快, 随机抖动性大, 收敛后精度低;
- ✓ 小步长($\mu = 0.05$): 较为平稳, 精度高, 收敛缓慢



3. LMS算法的权值期望 $E[\mathbf{w}(n)]$ 性能

- 将LMS算法的迭代公式展开，可得

$$\begin{aligned}\mathbf{w}(n+1) &= \mathbf{w}(n) + \mu[\mathbf{u}(n)e^*(n)] \\ &= \mathbf{w}(n) + \mu\{\mathbf{u}(n)[d^*(n) - \mathbf{u}^H(n)\mathbf{w}(n)]\}\end{aligned}$$

- 上式两边取期望，可得

$$\begin{aligned}E[\mathbf{w}(n+1)] &= E[\mathbf{w}(n)] + \mu E[\mathbf{u}(n)d^*(n)] \\ &\quad - \mu E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)]\end{aligned}$$

➤ 将LMS算法的迭代公式展开，可得

$$\begin{aligned}\mathbf{w}(n+1) &= \mathbf{w}(n) + \mu[\mathbf{u}(n)e^*(n)] \\ &= \mathbf{w}(n) + \mu\{\mathbf{u}(n)[d^*(n) - \mathbf{u}^H(n)\mathbf{w}(n)]\}\end{aligned}$$

➤ 上式两边取期望，可得

$$\begin{aligned}E[\mathbf{w}(n+1)] &= E[\mathbf{w}(n)] + \mu E[\mathbf{u}(n)d^*(n)] \\ &\quad - \mu E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)]\end{aligned}$$

- 在步长取值很小的情况下，近似有

$$E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)] = E[\mathbf{u}(n)\mathbf{u}^H(n)]E[\mathbf{w}(n)]$$

- 则有 $E[\mathbf{w}(n+1)] = E[\mathbf{w}(n)] + \mu E[\mathbf{u}(n)d^*(n)]$
 $-\mu E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)]$

上式可简化成

$$\begin{aligned} E[\mathbf{w}(n+1)] &= E[\mathbf{w}(n)] - \mu \mathbf{R} E[\mathbf{w}(n)] + \mu \mathbf{p} \\ &= E[\mathbf{w}(n)] - \mu \mathbf{R} E[\mathbf{w}(n)] + \mu \mathbf{R} \mathbf{w}_o \\ &= E[\mathbf{w}(n)] - \mu \mathbf{R} \{E[\mathbf{w}(n)] - \mathbf{w}_o\} \end{aligned}$$

$$E[\mathbf{w}(n+1)] = E[\mathbf{w}(n)] - \mu \mathbf{R} \{E[\mathbf{w}(n)] - \mathbf{w}_o\}$$

令 $\mathbf{v}(n) = E[\mathbf{w}(n)] - \mathbf{w}_o$, 上式两边同时减去 \mathbf{w}_o 得

$$\mathbf{v}(n+1) = \mathbf{v}(n) - \mu \mathbf{R} \mathbf{v}(n) = \mathbf{Q}[\mathbf{I} - \mu \mathbf{\Lambda}] \mathbf{Q}^H \mathbf{v}(n)$$

两边同乘 \mathbf{Q}^H , 上式可化为

$$\mathbf{v}'(n+1) = [\mathbf{I} - \mu \mathbf{\Lambda}] \mathbf{v}'(n)$$

由式 $\mathbf{v}'(n+1) = [\mathbf{I} - \mu\mathbf{\Lambda}]\mathbf{v}'(n)$ 递推, 可得

$$\mathbf{v}'(1) = [\mathbf{I} - \mu\mathbf{\Lambda}]^1 \mathbf{v}'(0)$$

$$\mathbf{v}'(2) = [\mathbf{I} - \mu\mathbf{\Lambda}]\mathbf{v}'(1) = [\mathbf{I} - \mu\mathbf{\Lambda}]^2 \mathbf{v}'(0)$$

\vdots

$$\mathbf{v}'(n) = [\mathbf{I} - \mu\mathbf{\Lambda}]^n \mathbf{v}'(0)$$

由上式可得如下结论:

- ✓ 每次迭代, 权值误差均值以 $[\mathbf{I} - \mu\mathbf{\Lambda}]$ 速度衰减。

□ 权值期望误差指数衰减的时间常数

- ✓ 每次迭代，权值误差均值以 $[\mathbf{I} - \mu\mathbf{\Lambda}]$ 速度衰减。

如果权向量有 M 个分量，相关矩阵就有 M 个特征值，则权值的衰减具有：

- ✓ M 个特征衰减模式，其

第 m 个权值期望以 $(1 - \mu\lambda_m)$ 速度衰减。

定义 $\gamma_m = 1 - \mu\lambda_m$ 。如果将 γ_m 看成随迭代次数 n 作指数衰减，则有

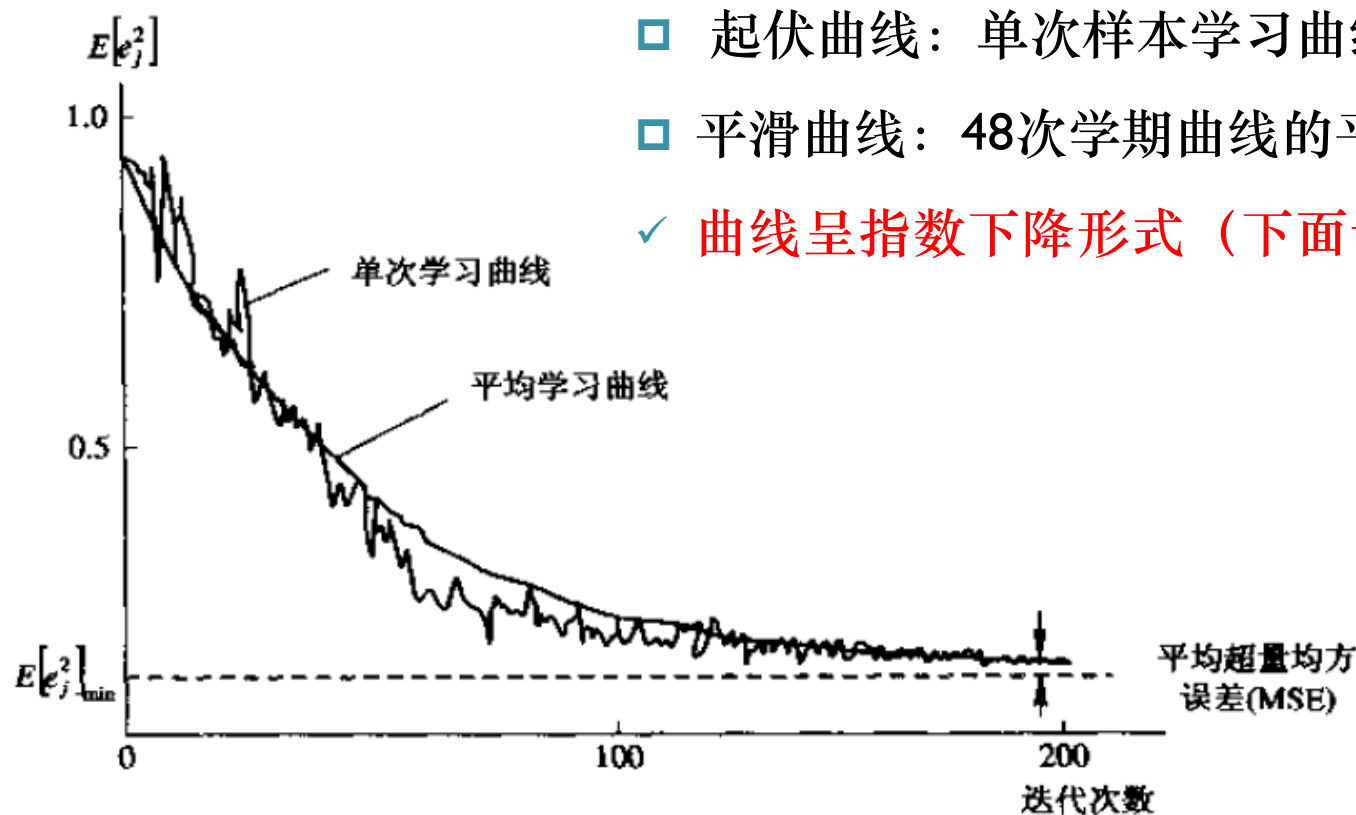
$$\gamma_m = e^{-1/\tau_m} = 1 - \frac{1}{\tau_m} + \frac{1}{2!\tau_m^2} + \dots$$

对于比较缓慢而平稳的自适应过程， τ_m 一般较大，因此可以略去等式右边的高次项，即

$$\gamma_m = 1 - \mu\lambda_m \approx 1 - \frac{1}{\tau_m} \quad \Rightarrow \quad \tau_m = \frac{1}{\mu\lambda_m}$$

4. LMS算法的均方误差 $E[|e(n)|^2]$ 性能

- 自适应滤波器的 $w(n)$ 需要经过一个迭代过程才能达到 w_o ，即 $E[e^2(n)]$ 趋于 $E[e^2(n)]_{\min}$ 需要一个过程。



□ 起伏曲线：单次样本学习曲线

□ 平滑曲线：48次学习曲线平均

✓ 曲线呈指数下降形式（下面证明）

$$\begin{aligned}
 E[|e(n)|^2] &= E\left\{\left[d(n) - \mathbf{w}^H(n)\mathbf{u}(n)\right]^2\right\} \\
 &= E\left[|d(n)|^2\right] - \mathbf{p}^H E[\mathbf{w}(n)] - E[\mathbf{w}(n)]^H \mathbf{p} + E[\mathbf{w}(n)]^H \mathbf{R} E[\mathbf{w}(n)]
 \end{aligned}$$

将维纳解 $\mathbf{w} = \mathbf{w}_o = R^{-1}\mathbf{p}$ 代入均方误差表达式，得

$$\begin{aligned}
 E\left[|e(n)|^2\right]_{\min} &= E\left[|d(n)|^2\right] - \mathbf{p}^H \mathbf{w}_o - \mathbf{w}_o^H \mathbf{p} + \mathbf{w}_o^H \mathbf{R} \mathbf{w}_o \\
 &= E\left[|d(n)|^2\right] - \mathbf{p}^H \mathbf{w}_o \quad (\mathbf{p} = \mathbf{R} \mathbf{w}_o)
 \end{aligned}$$

$$\begin{cases} E[|e(n)|^2] = E[|d(n)|^2] - \mathbf{p}^H E[\mathbf{w}(n)] \\ \quad - E[\mathbf{w}(n)]^H \mathbf{p} + E[\mathbf{w}(n)]^H \mathbf{R} E[\mathbf{w}(n)] \\ E[|e(n)|^2]_{\min} = E[d^2(n)] - \mathbf{p}^H \mathbf{w}_o \end{cases}$$

由上述两式，可得

$$\begin{aligned} E[|e(n)|^2] &= E[|e(n)|^2]_{\min} + \mathbf{p}^H \mathbf{w}_o - \mathbf{p}^H E[\mathbf{w}(n)] \\ &\quad - E[\mathbf{w}(n)]^H \mathbf{p} + E[\mathbf{w}(n)]^H \mathbf{R} E[\mathbf{w}(n)] \end{aligned}$$

令 $\mathbf{v}(n) = \mathbf{w}(n) - \mathbf{w}_o$ ，进一步转换，可得


$$\begin{aligned} E\left[|e(n)|^2\right] &= E[|e(n)|^2]_{\min} + \mathbf{p}^H \mathbf{w}_o - \mathbf{p}^H E[\mathbf{w}(n)] \\ &\quad - E[\mathbf{w}(n)]^H \mathbf{p} + E[\mathbf{w}(n)]^H \mathbf{R} E[\mathbf{w}(n)] \\ &= E[|e(n)|^2]_{\min} + \mathbf{w}_o^H \mathbf{R} \mathbf{w}_o - \mathbf{w}_o^H \mathbf{R} E[\mathbf{w}(n)] \\ &\quad - E[\mathbf{w}(n)]^H \mathbf{R} \mathbf{w}_o + E[\mathbf{w}(n)]^H \mathbf{R} E[\mathbf{w}(n)] \\ &= E[|e(n)|^2]_{\min} + \{E[\mathbf{w}(n)] - \mathbf{w}_o\}^H \mathbf{R} \{E[\mathbf{w}(n)] - \mathbf{w}_o\} \\ &= E[|e(n)|^2]_{\min} + \mathbf{v}^H(n) \mathbf{R} \mathbf{v}(n) \end{aligned}$$

根据特征值分解，令 $\mathbf{R} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^H$ ，则有

$$\begin{aligned} E\left[|e(n)|^2\right] &= E[|e(n)|^2]_{\min} + \mathbf{v}^H(n)\mathbf{R}\mathbf{v}(n) \\ &= E[|e(n)|^2]_{\min} + \mathbf{v}^H(n)\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^H\mathbf{v}(n) \\ &= E[|e(n)|^2]_{\min} + \left[\mathbf{Q}^H\mathbf{v}(n)\right]^H\mathbf{\Lambda}\mathbf{Q}^H\mathbf{v}(n) \\ &= E[|e(n)|^2]_{\min} + \mathbf{v}'^H(n)\mathbf{\Lambda}\mathbf{v}'(n) \end{aligned}$$

其中， $\mathbf{v}'(n) = \mathbf{Q}^H\mathbf{v}(n)$ 。

□ 二维情况举例说明几何意义(以实数为例)



✓ 均方误差超抛物面在水平面上的投影;

✓ 误差椭圆重心不一定在该坐标的原点;

✓ \mathbf{v} 坐标系以误差椭圆的重心为原点;

✓ \mathbf{v}' 为主轴:

平移: $\mathbf{v}(n) = \mathbf{w}(n) - \mathbf{w}_o$;

旋转: $\mathbf{v}'(n) = \mathbf{Q}^T \mathbf{v}(n)$ 。

□ 均方误差指数衰减的时间常数

由 $E[|e(n)|^2] = E[|e(n)|^2]_{\min} + \mathbf{v}'^H(n) \mathbf{\Lambda} \mathbf{v}'(n)$ 可得

$$E[|e(n)|^2] = E[|e(n)|^2]_{\min} + \mathbf{v}'^H(0) \mathbf{\Lambda} [\mathbf{I} - \mu \mathbf{\Lambda}]^{2n} \mathbf{v}'(0)$$

(提示: $\mathbf{v}'(n+1) = [\mathbf{I} - \mu \mathbf{\Lambda}] \mathbf{v}'(n)$)

结论:

- ✓ 每次迭代, 等式右边第二项以 $[\mathbf{I} - \mu \mathbf{\Lambda}]^2$ 速度衰减;
- ✓ 当 $n \rightarrow \infty$ 时, $E[|e(n)|^2] = E[|e(n)|^2]_{\min}$;
- ✓ $E[e^2(n)]$ 随 n 增加的衰减比 $w(n)$ 衰减快一倍。

如果权向量有 M 个分量，则权值误差均方误差的衰减具有 M 个特征振动模式。

定义 $\gamma_m^2 = (1 - \mu\lambda_m)^2$ 。 如将 $(\gamma_m^2)^n$ 看成随迭代次数 n 作指数衰减，则有

$$\gamma_m^2 = [1 - \mu\lambda_m]^2 = e^{-1/\tau_{mse}} \Rightarrow \gamma_m = 1 - \mu\lambda_m = e^{-1/(2\tau_{mse})}$$

$$\gamma_m = 1 - \mu\lambda_m = e^{-1/(2\tau_{mse})}$$

采用泰勒展开，上式可表示为

$$\gamma_m = 1 - \mu\lambda_m = e^{-1/(2\tau_{mse})} = 1 - \frac{1}{2\tau_{mse}} + \frac{1}{2!(2\tau_{mse})^2} + \dots$$

略去等式右边的高次项，即

$$1 - \mu\lambda_m \approx 1 - \frac{1}{2\tau_{mse}} \Rightarrow \tau_{mse} = \frac{1}{2\mu\lambda_m}$$

◆ 随 n 增加， $E[e^2(n)]$ 的衰减比 $w(n)$ 衰减快一倍。


□ 决定衰减快慢的主要因素

- ✓ 对应于 M 个权值的自适应滤波器，其权值误差向量的衰减，是由 M 个自由衰减模式决定；
- ✓ 在最不利的情况下，具有最大衰减常数的分量对衰减起主导作用；
- ✓ 一般情况下的收敛速度由最大时间常数决定，

- 令 \mathbf{R} 的最小和最大特征值分别为 λ_{\min} 和 λ_{\max} 。
- 如果按照之前的条件 $0 < \mu < 2 / \lambda_{\max}$ 取步长的上界 $\mu = 2 / \lambda_{\max}$ ，则最大的时间常数为

$$\tau_{\max} = \frac{1}{\mu \lambda_{\min}} \geq \frac{1}{2} \frac{\lambda_{\max}}{\lambda_{\min}}$$

- $\lambda_{\max} / \lambda_{\min}$ 称为输入信号相关矩阵的特征值扩散度。因此，输入信号相关矩阵的特征值扩散度越大，最大的时间常数 τ_{\max} 就越大，自适应滤波器收敛就越慢。

- 
- 白噪声对应相关矩阵的特征值扩散度最小，即 $\lambda_{\max} / \lambda_{\min} = 1$ ，因而收敛最快；
 - 随着信号的相关性越强，其对应相关矩阵的特征值扩散度越大，因而收敛越慢；

- ◆ 因此，LMS算法的主要缺点是，当输入信号的相关矩阵特征值较大时，收敛很慢。
- ✓ 解决思路：将输入信号去相关（白化）
- ✓ 主要算法：LMS格型算法、RLS算法、仿射投影算法、子带自适应算法等。

□ 梯度噪声引起的失调

- ✓ 理想情况下，在自适应过程中，若没有环境噪声引起的误差，权向量 $\mathbf{w}(n)$ 最终将收敛于均方性能曲面的最小点 \mathbf{w}_o ；
- ✓ 在此条件下，向量 $\mathbf{v}(n)$ 的协方差为0，均方误差 $E[|e(n)|^2] = E[|e(n)|^2]_{\min} = \sigma_v^2$ 。

- ✓ 实际上，一般只能使 $E[\mathbf{w}(n)] = \mathbf{w}_o$ ，这是因为LMS算法用瞬时梯度代替梯度时会产生梯度估计误差(梯度噪声)。
- ✓ 梯度噪声导致 $\mathbf{w}(n)$ 的值随机起伏。这意味着即使滤波器达到了稳态，均方误差 $E[|e(n)|^2]$ 任然大于 $E[|e(n)|^2]_{\min} = \sigma_v^2$ 。

- ✓ 定义超量均方误差为 $\zeta = E[|e(n)|^2] - \sigma_v^2$
- ✓ 归一化后的超量均方误差，称为失调，即

$$M = \frac{\zeta}{\sigma_v^2}$$

- ✓ 该量可以近似为

$$M = \mu \text{tr}[\mathbf{R}]$$

即，失调正比于步长。




图 4.13 由于梯度噪声而造成的超量均方误差