



第四章 自适应滤波




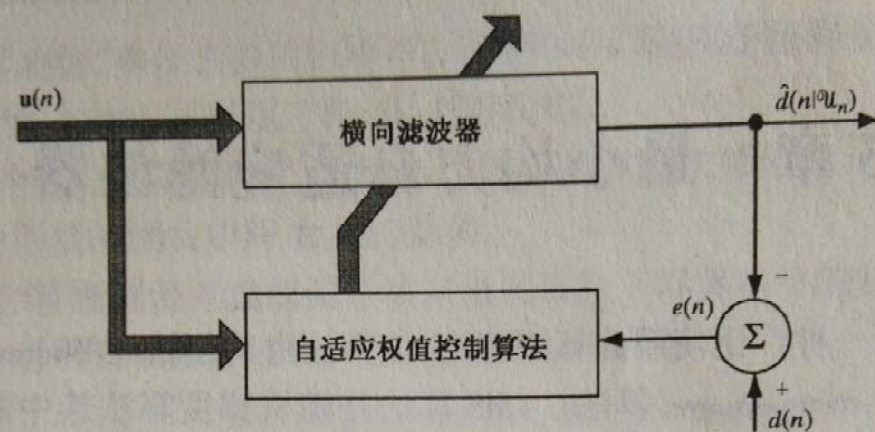
§ 4.1 自适应滤波器的基本概念

➤ 应用维纳滤波器的封闭解和数值解，需要已知：输入信号的**相关矩阵 \mathbf{R}** 和输入信号与期望响应之间的**互相关向量 \mathbf{p}** 。

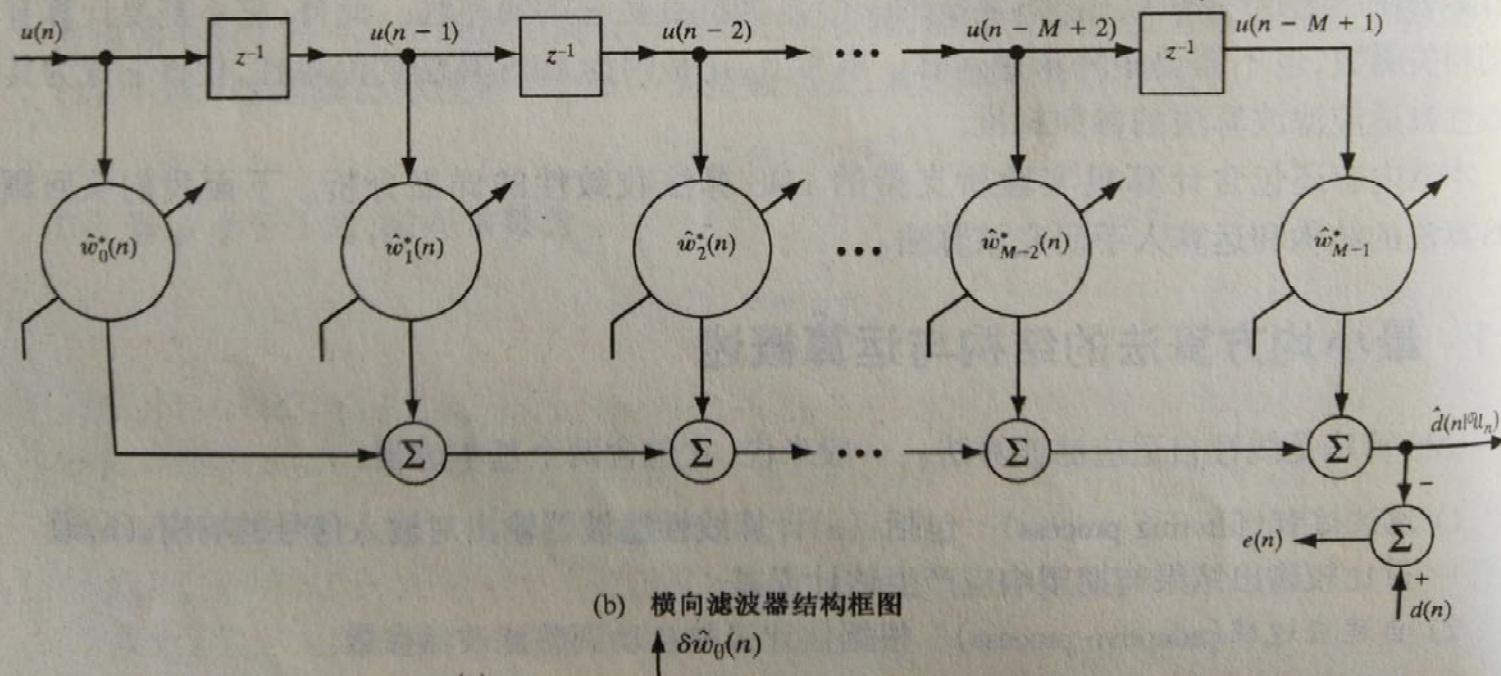
➤ 实际应用中：

- ◆ (1) 信号的相关矩阵 \mathbf{R} 和互相关向量 \mathbf{p} 大部分情况下是未知的。
- ◆ (2) 如果信号是时变的，则相关矩阵 \mathbf{R} 和互相关向量 \mathbf{p} 是时变的。

- 
- 对于 \mathbf{R} 和 \mathbf{p} 是未知，甚至是时变的情形，需要一种能够实时估计或者跟踪信号统计特性的方法，即 **自适应滤波** 方法。
 - 一个自适应滤波器，包含如下三个过程
 - ◆ 滤波过程：计算线性滤波器输出对输入信号的响应；
 - ◆ 计算估计误差：通过比较输出结果与期望响应产生估计误差。
 - ◆ 自适应过程：根据估计误差自动调整滤波器参数。



(a) 自适应横向滤波器框图



(b) 横向滤波器结构框图



§ 4.2 LMS自适应滤波算法

- 前面推导的最速下降算法迭代式为

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \mu[\mathbf{p} - \mathbf{R}\mathbf{w}(n)]$$

其中， $\mathbf{R} = E[\mathbf{u}(n)\mathbf{u}^H(n)]$, $\mathbf{p} = E[\mathbf{u}(n)d(n)]$

- 为了能够实时处理，可以采用信号的瞬时值来近似估计，即

$$\hat{\mathbf{R}}(n) = \mathbf{u}(n)\mathbf{u}^H(n), \quad \hat{\mathbf{p}}(n) = \mathbf{u}(n)d(n)$$

- 将上式代入最速下降算法迭代式，可得

$$\begin{aligned}
 \mathbf{w}(n+1) &= \mathbf{w}(n) + \mu \left[\overbrace{\mathbf{u}(n)d^*(n)}^{\hat{\mathbf{p}}(n)} - \overbrace{\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)}^{\hat{\mathbf{R}}(n)} \right] \\
 &= \mathbf{w}(n) + \mu \mathbf{u}(n) \left[d^*(n) - \mathbf{u}^H(n)\mathbf{w}(n) \right] \\
 &= \mathbf{w}(n) + \mu \mathbf{u}(n) \left[d(n) - \overbrace{\mathbf{w}^H(n)\mathbf{u}(n)}^{y(n)} \right]^* \\
 &= \mathbf{w}(n) + \mu \mathbf{u}(n) e^*(n)
 \end{aligned}$$

上式即为**最小均方(LMS)算法**的迭代公式。

最小均方(LMS)算法的迭代公式，包含三个过程：

1) 滤波输出： $y(n) = \mathbf{w}^H(n)\mathbf{u}(n)$

2) 计算估计误差： $e(n) = d(n) - y(n)$

3) 权值向量自适应： $\mathbf{w}(n+1) = \mathbf{w}(n) + \mu\mathbf{u}(n)e^*(n)$

表 5.1 LMS 算法小结

参数:

$M =$ 抽头数(即滤波器长度)

$\mu =$ 步长参数

$$0 < \mu < \frac{2}{MS_{\max}}$$

其中 S_{\max} 是抽头输入 $u(n)$ 的功率谱密度的最大值, 而滤波器长度 M 为中到大

初始化:

如果知道抽头权向量 $\hat{\mathbf{w}}(n)$ 的先验知识, 则用它来选择 $\hat{\mathbf{w}}(0)$ 的适当值; 否则令 $\hat{\mathbf{w}}(0) = \mathbf{0}$

数据:

● 给定的: $\mathbf{u}(n) = n$ 时刻 $M \times 1$ 抽头输入向量

$$= [u(n), u(n-1), \dots, u(n-M+1)]^T$$

$d(n) = n$ 时刻的期望响应

● 要计算的: $\hat{\mathbf{w}}(n+1) = n+1$ 时刻抽头权向量估计

计算: 对 $n = 0, 1, 2, \dots$, 计算

$$e(n) = d(n) - \hat{\mathbf{w}}^H(n) \mathbf{u}(n)$$

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \mu \mathbf{u}(n) e^*(n)$$



§ 4.3 LMS算法的收敛性

1. LMS算法收敛性证明

- 将LMS算法的迭代公式展开，可得

$$\begin{aligned}\mathbf{w}(n+1) &= \mathbf{w}(n) + \mu[\mathbf{u}(n)e^*(n)] \\ &= \mathbf{w}(n) + \mu\{\mathbf{u}(n)[d^*(n) - \mathbf{u}^H(n)\mathbf{w}(n)]\}\end{aligned}$$

- 上式两边取期望，可得

$$\begin{aligned}E[\mathbf{w}(n+1)] &= E[\mathbf{w}(n)] + \mu E[\mathbf{u}(n)d^*(n)] \\ &\quad - \mu E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)]\end{aligned}$$

- 在步长取值很小的情况下， $\mathbf{w}(n)$ 变化很慢，可以近似为与输入向量 $\mathbf{u}(n)$ 不相关，则近似有

$$E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)] = E[\mathbf{u}(n)\mathbf{u}^H(n)]E[\mathbf{w}(n)]$$

- 于是，迭代式

$$\begin{aligned} E[\mathbf{w}(n+1)] &= E[\mathbf{w}(n)] + \mu E[\mathbf{u}(n)d^*(n)] \\ &\quad - \mu E[\mathbf{u}(n)\mathbf{u}^H(n)\mathbf{w}(n)] \end{aligned}$$

可简化成

$$E[\mathbf{w}(n+1)] = (\mathbf{I} - \mu\mathbf{R})E[\mathbf{w}(n)] + \mu\mathbf{p}$$

► 设初始权值为 $\mathbf{w}(0)$ ，则有上式递推可得

$$E[\mathbf{w}(1)] = (\mathbf{I} - \mu\mathbf{R})E[\mathbf{w}(0)] + \mu\mathbf{p}$$

$$E[\mathbf{w}(2)] = (\mathbf{I} - \mu\mathbf{R})E[\mathbf{w}(1)] + \mu\mathbf{p}$$

$$= (\mathbf{I} - \mu\mathbf{R})^2 E[\mathbf{w}(0)] + \mu(\mathbf{I} - \mu\mathbf{R})\mathbf{p} + \mu\mathbf{p}$$

\vdots

$$E[\mathbf{w}(n+1)] = (\mathbf{I} - \mu\mathbf{R})^{n+1} E[\mathbf{w}(0)] + \mu \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{R})^i \mathbf{p}$$

➤ 根据特征值分解，可令 $\mathbf{R} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^H$

其中， \mathbf{Q} 为酉矩阵，满足 $\mathbf{Q}\mathbf{Q}^H = \mathbf{I}$, $\mathbf{Q}^H = \mathbf{Q}^{-1}$

$$\mathbf{\Lambda} = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & 0 \\ & & \vdots & \\ 0 & & & \lambda_M \end{pmatrix}$$

➤ 则递推式

$$E[\mathbf{w}(n+1)] = (\mathbf{I} - \mu\mathbf{R})^{n+1} E[\mathbf{w}(0)] + \mu \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{R})^i \mathbf{p}$$

可转化为

$$\begin{aligned} E[\mathbf{w}(n+1)] &= (\mathbf{I} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1})^{n+1} E[\mathbf{w}(0)] \\ &\quad + \mu \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1})^i \mathbf{p} \end{aligned}$$

► 根据酉矩阵的性质 $\mathbf{Q}\mathbf{Q}^H = \mathbf{I}$, $\mathbf{Q}^H = \mathbf{Q}^{-1}$, 递推式

$$E[\mathbf{w}(n+1)] = (\mathbf{I} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1})^{n+1} E[\mathbf{w}(0)]$$

$$+ \mu \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1})^i \mathbf{p}$$

等号右边第一项的矩阵可写为

$$\begin{aligned} (\mathbf{I} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1})^n &= (\mathbf{Q}\mathbf{Q}^{-1} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1})^n \\ &= [\mathbf{Q}(\mathbf{I} - \mu\mathbf{\Lambda})\mathbf{Q}^{-1}]^n \\ &= \mathbf{Q}(\mathbf{I} - \mu\mathbf{\Lambda})^n \mathbf{Q}^{-1} \end{aligned}$$

➤ 则递推式可转化为

$$E[\mathbf{w}(n+1)] = \mathbf{Q}(\mathbf{I} - \mu\mathbf{\Lambda})^{n+1} \mathbf{Q}^{-1} E[\mathbf{w}(0)]$$

$$+ \mu \mathbf{Q} \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{\Lambda})^i \mathbf{Q}^{-1} \mathbf{p}$$

要使上式收敛，必须满足如下条件：

$$|1 - \mu\lambda_{\max}| < 1 \quad \Rightarrow \quad 0 < \mu < \frac{2}{\lambda_{\max}}$$

➤ 条件 $0 < \mu < 2 / \lambda_{\max}$ 需要知道相关矩阵的特征值，而实际应用中可能是未知的。

➤ 由于 $\lambda_{\max} < \sum_{i=0}^{M-1} \lambda_{i+1} = \text{tr}[\mathbf{R}] = \sum_{i=0}^{M-1} E[u^2(i)]$ ，则步长的范围可缩小为

$$0 < \mu < \frac{2}{\sum_{i=1}^N E[u_i^2]}$$

其中， $\sum_{i=0}^{M-1} E[u_i^2]$ 为输入信号的功率，通常可以估计。

◆ 下面证明，当 $n \rightarrow \infty$ 时， $\mathbf{w}(n)$ 收敛于何处。

➤ 当 $n \rightarrow \infty$ 时，递推式

$$E[\mathbf{w}(n+1)] = \mathbf{Q}(\mathbf{I} - \mu\mathbf{\Lambda})^{n+1} \mathbf{Q}^{-1} E[\mathbf{w}(0)] \\ + \mu \mathbf{Q} \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{\Lambda})^i \mathbf{Q}^{-1} \mathbf{p}$$

转化为

$$\lim_{n \rightarrow \infty} E[\mathbf{w}(n+1)] = \mu \mathbf{Q} \lim_{n \rightarrow \infty} \sum_{i=0}^n (\mathbf{I} - \mu\mathbf{\Lambda})^i \mathbf{Q}^{-1} \mathbf{p}$$

► 递推式中的矩阵 $\lim_{n \rightarrow \infty} \sum_{i=0}^n (\mathbf{I} - \mu \mathbf{\Lambda})^i$ 可转化为

$$\lim_{n \rightarrow \infty} \sum_{i=0}^n (\mathbf{I} - \mu \mathbf{\Lambda})^i = [\mathbf{I} - (\mathbf{I} - \mu \mathbf{\Lambda})]^{-1} = \frac{1}{\mu} \mathbf{\Lambda}^{-1}$$

将上式代入递推式

$$\lim_{n \rightarrow \infty} E[\mathbf{w}(n+1)] = \mu \mathbf{Q} \lim_{n \rightarrow \infty} \sum_{i=0}^n (\mathbf{I} - \mu \mathbf{\Lambda})^i \mathbf{Q}^{-1} \mathbf{p}$$

$$\begin{aligned} \text{可得 } \lim_{n \rightarrow \infty} E[\mathbf{w}(n+1)] &= \mu \mathbf{Q} \frac{1}{\mu} \mathbf{\Lambda}^{-1} \mathbf{Q}^{-1} \mathbf{p} = \mathbf{Q} \mathbf{\Lambda}^{-1} \mathbf{Q}^{-1} \mathbf{p} \\ &= \mathbf{Q} \mathbf{\Lambda}^{-1} \mathbf{Q}^H \mathbf{p} = \mathbf{R}^{-1} \mathbf{p} = \mathbf{w}_o \end{aligned}$$

2. 步长参数对稳定性和收敛速度的影响 (以实数为例)

■ 权值向量为一维的情况

$$\Delta w(n) = w(n) - w_o$$

- 可以证明， $\Delta w(n)$ 越大，则在点 $w(n)$ 处的斜率 $\hat{\nabla}(n)$ 越大。
- 在 n 点处的瞬时估计为

$$\begin{aligned}\hat{\nabla}(n) &= \frac{\partial e^2(n)}{\partial w(n)} = 2e(n) \frac{\partial e(n)}{\partial w(n)} \\ &= -2d(n)u(n) + 2w(n)u^2(n)\end{aligned}$$




图 4.8 一维情况下的 $E[e_j^2] \sim W$ 及 $\hat{\nabla}_j \sim W$ 关系

➤ 可见，在 n 点处的瞬时估计

$$\hat{\nabla}(n) = -2d(n)u(n) + 2w(n)u^2(n)$$

与 $w(n)$ 的关系，为一条直线，其斜率为

$$\frac{\partial \hat{\nabla}(n)}{\partial w(n)} = 2u^2(n)$$

即， $\hat{\nabla}(n)$ 正比于 $w(n)$ 。

➤ 根据最速下降法公式 $w(n+1) = w(n) - \frac{1}{2}\mu\hat{\nabla}(n)$ 每递推一次， $w(n)$ 向 w_o 靠拢的量为

$$\Delta w = w(n) - w(n+1) = \mu u^2(n) \Delta w(n)$$


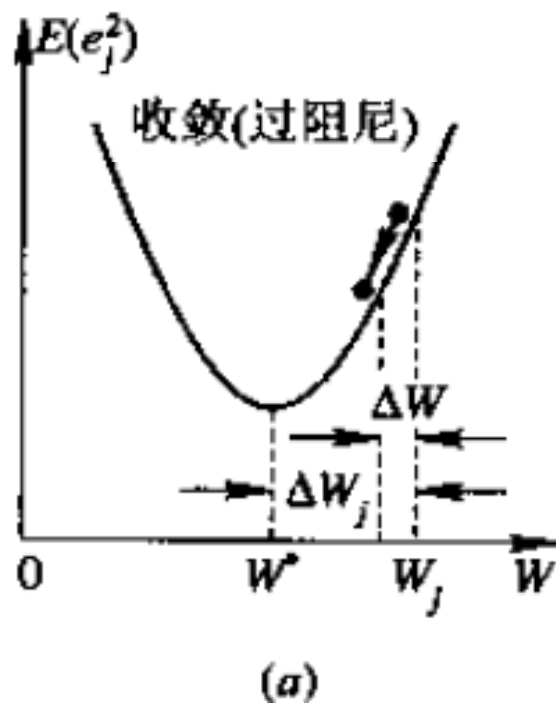


图 4.8 一维情况下的 $E[e_j^2] \sim W$ 及 $\hat{\nabla}_j \sim W$ 关系


□ 根据 $\Delta w = \mu u^2(n) \Delta w(n)$ ，容易看出

- a) 在 $\Delta w < \Delta w(n)$ 的范围内， μ 越大， Δw 越大，收敛越快。此情况称为过阻尼。



□ 根据 $\Delta w = \mu u^2(n) \Delta w(n)$ ，容易看出


b) μ 加大，但满足 $\Delta w(n) < \Delta w < 2\Delta w(n)$ 的条件，此时将以震荡型轨迹收敛于 w_0 。此情况称为欠阻尼。



(b)


□ 根据 $\Delta w = \mu u^2(n) \Delta w(n)$ ，容易看出

- c) 当 μ 取值增大，使 $\Delta w = 2\Delta w(n)$ 时，此时的 $w(n)$ 将不能收敛于 w_o 。此情况称为临界阻尼。



□ 根据 $\Delta w = \mu u^2(n) \Delta w(n)$ ，容易看出

d) 当 μ 取值过大，使 $\Delta w > 2\Delta w(n)$ 时，此时的 $w(n)$ 将发散，不再收敛于任何值。



- 通常情况下，为了获得比较小的逼近误差，步长 μ 的值一般取的很小，从而不太会出现 (b)(c)(d) 的情况。





图 4.9 μ 的大小对收敛的影响


■ 权值向量为二维的情况

- ✓ 大步长($\mu = 0.1$): 收敛速度快, 随机抖动性大, 收敛后精度低;
- ✓ 小步长($\mu = 0.05$): 较为平稳, 精度高, 收敛缓慢



3. 自适应算法的学习曲线(以实数为例)

- 自适应滤波器的 $w(n)$ 需要经过一个迭代过程才能达到 w_o ，即 $E[e^2(n)]$ 趋于 $E[e^2(n)]_{\min}$ 需要一个过程。



➤ 将维纳解 $\mathbf{w} = \mathbf{w}_o = R^{-1}\mathbf{p}$ 代入均方误差表达式

$$E[e^2(n)] = E[d^2(n)] - 2\mathbf{p}^T \mathbf{w} + \mathbf{w}^T \mathbf{R} \mathbf{w}$$

可得

$$\begin{aligned} E[e^2(n)]_{\min} &= E[d^2(n)] - 2\mathbf{p}^T \mathbf{w}_o + \mathbf{w}_o^T \mathbf{R} \mathbf{w}_o \\ &= E[d^2(n)] - 2\mathbf{p}^T \mathbf{w}_o + \mathbf{w}_o^T \mathbf{p} \\ &= E[d^2(n)] - \mathbf{w}_o^T \mathbf{p} \end{aligned}$$

则用下式表示上式，可得

$$E[e^2(n)] = E[e^2(n)]_{\min} + \mathbf{w}_o^T \mathbf{p} - 2\mathbf{p}^T \mathbf{w} + \mathbf{w}^T \mathbf{R} \mathbf{w}$$

令 $\mathbf{v}(n) = \mathbf{w}(n) - \mathbf{w}_o$ ，进一步化简，可得

$$E[e^2(n)]$$

$$= E[e^2(n)]_{\min} + \mathbf{w}_o^T \mathbf{p} - 2\mathbf{p}^T \mathbf{w}(n) + \mathbf{w}^T(n) \mathbf{R} \mathbf{w}(n)$$

$$= E[e^2(n)]_{\min} + \mathbf{w}_o^T \mathbf{R} \mathbf{w}_o - 2\mathbf{w}_o^T \mathbf{R} \mathbf{w}(n) + \mathbf{w}^T(n) \mathbf{R} \mathbf{w}(n)$$

$$= E[e^2(n)]_{\min} + (\mathbf{w}(n) - \mathbf{w}_o)^T \mathbf{R} (\mathbf{w}(n) - \mathbf{w}_o)$$

$$= E[e^2(n)]_{\min} + \mathbf{v}^T(n) \mathbf{R} \mathbf{v}(n)$$


$$= E[e^2(n)]_{\min} + \mathbf{v}^T(n) \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T \mathbf{v}(n)$$

根据特征值分解，令 $\mathbf{R} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$ ，则有

$$\begin{aligned} E[e^2(n)] &= E[e^2(n)]_{\min} + \mathbf{v}^T(n)\mathbf{R}\mathbf{v}(n) \\ &= E[e^2(n)]_{\min} + \mathbf{v}^T(n)\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T\mathbf{v}(n) \\ &= E[e^2(n)]_{\min} + \left[\mathbf{Q}^T\mathbf{v}(n)\right]^T \mathbf{\Lambda}\mathbf{Q}^T\mathbf{v}(n) \\ &= E[e^2(n)]_{\min} + \mathbf{v}'^T(n)\mathbf{\Lambda}\mathbf{v}'(n) \end{aligned}$$

其中， $\mathbf{v}'(n) = \mathbf{Q}^T\mathbf{v}(n)$ 。

□ 权值向量为二维情况举例说明几何意义



- ✓ 均方误差超抛物面在水平面上的投影;
- ✓ 误差椭圆重心不一定在该坐标的原点;
- ✓ \mathbf{v} 坐标系以误差椭圆的重心为原点;
- ✓ \mathbf{v}' 为主轴:
平移: $\mathbf{v}(n) = \mathbf{w}(n) - \mathbf{w}_o$;
旋转: $\mathbf{v}'(n) = \mathbf{Q}^T \mathbf{v}(n)$ 。

□ 求权值误差指数衰减的时间常数

将均方误差 $E[e^2(n)] = E[e^2(n)]_{\min} + \mathbf{v}^T(n)\mathbf{R}\mathbf{v}(n)$

对 $\mathbf{w}(n)$ 取微分, 可得 $\nabla_n = 2\mathbf{R}\mathbf{V}(n)$

根据最速下降法 $\mathbf{w}(n+1) = \mathbf{w}(n) - \frac{\mu}{2}\nabla_n$, 有

$$\mathbf{w}(n+1) - \mathbf{w}_o = \mathbf{w}(n) - \mathbf{w}_o - \mu\mathbf{R}\mathbf{V}(n)$$

即有 $\mathbf{v}(n+1) = \mathbf{v}(n) - \mu\mathbf{R}\mathbf{v}(n) = \mathbf{Q}[\mathbf{I} - \mu\mathbf{\Lambda}]\mathbf{Q}^T\mathbf{v}(n)$

两边同乘 \mathbf{Q}^T , 上式简化为

$$\mathbf{v}'(n+1) = [\mathbf{I} - \mu\mathbf{\Lambda}]\mathbf{v}'(n)$$

由式 $\mathbf{v}'(n+1) = [\mathbf{I} - \mu\mathbf{\Lambda}]\mathbf{v}'(n)$ 递推, 可得

$$\mathbf{v}'(1) = [\mathbf{I} - \mu\mathbf{\Lambda}]^1 \mathbf{v}'(0)$$

$$\mathbf{v}'(2) = [\mathbf{I} - \mu\mathbf{\Lambda}]\mathbf{v}'(1) = [\mathbf{I} - \mu\mathbf{\Lambda}]^2 \mathbf{v}'(0)$$

\vdots

$$\mathbf{v}'(n) = [\mathbf{I} - \mu\mathbf{\Lambda}]^n \mathbf{v}'(0)$$

由上式可得如下结论:

- ✓ 每次迭代, 等式右边第二项以 $[\mathbf{I} - \mu\mathbf{\Lambda}]$ 速度衰减;
- ✓ 当 $n \rightarrow \infty$ 时, $\mathbf{w}(n) = \mathbf{w}_o$;



如果权向量有 M 个分量，则权值的衰减具有：

- ✓ M 个自由度；
- ✓ M 个特征值；
- ✓ M 个特征振动模式。

第 m 个振动模式的能量每次衰减为 $(1 - \mu\lambda_m)$ 。

定义 $\gamma_m = 1 - \mu\lambda_m$, 则 γ_m 随迭代次数 n 作**指数衰减**。

$$\text{所以 } \gamma_m = e^{-1/\tau_m} = 1 - \frac{1}{\tau_m} + \frac{1}{2!\tau_m^2} + \dots$$

对于比较缓慢而平稳的自适应过程, τ_m 一般较大, 因此可以略去等式右边的高次项, 即

$$\gamma_m = 1 - \mu\lambda_m \approx 1 - \frac{1}{\tau_m} \quad \Rightarrow \quad \tau_m = \frac{1}{\mu\lambda_m}$$


□ 均方误差指数衰减的时间常数

因为 $E[e^2(n)] = E[e^2(n)]_{\min} + \mathbf{v}'^T(n) \Lambda \mathbf{v}'(n)$ ，则有

$$E[e^2(n)] = E[e^2(n)]_{\min} + \mathbf{v}'^T(0) [\mathbf{I} - \mu \Lambda]^{2n} \mathbf{v}'(0)$$

由上式可得如下结论：

- ✓ 每次迭代，等式右边第二项以 $[\mathbf{I} - \mu \Lambda]^2$ 速度衰减；
- ✓ 当 $n \rightarrow \infty$ 时， $E[e^2(n)] = E[e^2(n)]_{\min}$ ；
- ✓ $E[e^2(n)]$ 随 n 增加的衰减比 $\mathbf{w}(n)$ 衰减快一倍。



如果权向量有 M 个分量，则权值误差均方误差的衰减具有：

- ✓ M 个自由度；
- ✓ M 个特征值；
- ✓ M 个特征振动模式。

定义 $\gamma_m^2 = (1 - \mu\lambda_m)^2$, 则 $(\gamma_m^2)^n$ 随迭代次数 n 作指数衰减。

$$\text{令 } \gamma_m^2 = [1 - \mu\lambda_m]^2 = e^{-1/\tau_{mse}} \Rightarrow \gamma_m = 1 - \mu\lambda_m = e^{-1/(2\tau_{mse})}$$

采用泰勒展开, 上式可表示为

$$\gamma_m = 1 - \mu\lambda_m = e^{-1/(2\tau_{mse})} = 1 - \frac{1}{2\tau_{mse}} + \frac{1}{2!(2\tau_{mse})^2} + \dots$$

略去等式右边的高次项, 即

$$1 - \mu\lambda_m \approx 1 - \frac{1}{2\tau_{mse}} \Rightarrow \tau_{mse} = \frac{1}{2\mu\lambda_m}$$

◆ 随 n 增加, $E[e^2(n)]$ 的衰减比 $w(n)$ 衰减快一倍。


□ 决定衰减快慢的主要因素

- ✓ 对应于 M 个权值的自适应滤波器，其权值误差向量的衰减，是由 M 个自由衰减模式决定；
- ✓ 在最不利的情况下，具有最大衰减常数的分量对衰减起主导作用；
- ✓ 一般情况下的收敛速度由最大时间常数决定，

- 令 \mathbf{R} 的最小和最大特征值分别为 λ_{\min} 和 λ_{\max} 。
- 如果按照之前的条件 $0 < \mu < 2 / \lambda_{\max}$ 取步长的上界 $\mu = 2 / \lambda_{\max}$ ，则最大的时间常数为

$$\tau_{\max} = \frac{1}{\mu \lambda_{\min}} \geq \frac{1}{2} \frac{\lambda_{\max}}{\lambda_{\min}}$$

- $\lambda_{\max} / \lambda_{\min}$ 称为输入信号相关矩阵的特征值扩散度。因此，输入信号相关矩阵的特征值扩散度越大，最大的时间常数 τ_{\max} 就越大，自适应滤波器收敛就越慢。

- 
- 白噪声对应相关矩阵的特征值扩散度最小，即 $\lambda_{\max} / \lambda_{\min} = 1$ ，因而收敛最快；
 - 随着信号的相关性越强，其对应相关矩阵的特征值扩散度越大，因而收敛越慢；
 - ◆ 因此，LMS算法的主要缺点是，当输入信号的相关矩阵特征值较大时，收敛很慢。
 - ✓ 解决思路：将输入信号去相关（白化）
 - ✓ 主要算法：LMS格型算法、RLS算法、仿射投影算法、子带自适应算法等。

□ 梯度噪声引起的失调

- ✓ 在自适应过程中，若没有环境噪声引起的误差，权向量 $\mathbf{w}(n)$ 最终将收敛于均方性能曲面的最小点 \mathbf{w}_o ；
- ✓ 在此条件下，向量 $\mathbf{v}(n)$ 的协方差为0，均方误差 $E[e^2(n)] = E[e^2(n)]_{\min}$ 。

- ✓ 实际上，一般只能使 $E[\mathbf{w}(n)] = \mathbf{w}_o$ ，这是因为LMS算法用瞬时梯度代替梯度时会产生梯度估计误差(梯度噪声)。
- ✓ 梯度噪声导致 $\mathbf{w}(n)$ 的值随机起伏。这意味着即使滤波器达到了稳态，均方误差 $E[e^2(n)]$ 任然大于 $E[e^2(n)]_{\min}$ 。

- ✓ 定义超量均方误差为 $\zeta = E[e^2(n)] - E[e^2(n)]_{\min}$
- ✓ 归一化后的超量均方误差，称为失调，即

$$M = \frac{\zeta}{E[e^2(n)]_{\min}}$$

- ✓ 该量可以近似为

$$M = \frac{\mu}{2} \text{tr}[\mathbf{R}]$$

- ✓ 失调正比于步长。




图 4.13 由于梯度噪声而造成的超量均方误差



§ 4.4 LMS格型自适应滤波器




前面介绍的LMS算法，基于横向滤波器。


其优点为：结构简单

其缺点为：收敛速度慢

克服LMS横向滤波器收敛速度慢的方法之一，
是采用**格型自适应滤波器**。



- P阶格型滤波器，由P个反射系数表示；
- P个反射系数： K_1, K_2, \dots, K_P
- P+1个前项预测误差： $e_0(n), e_1(n), \dots, e_P(n)$
- p+1个后项预测误差： $b_0(n), b_1(n), \dots, b_P(n)$



➤ 由格型滤波器的信号关系,可得:

$$\begin{cases} e_p(n) = e_{p-1}(n) + K_p b_{p-1}(n-1) \\ b_p(n) = b_{p-1}(n-1) + K_p e_{p-1}(n) \end{cases} \quad p \in \{1, 2, \dots, P\}$$

- 对前项预测误差 $e_p(n) = e_{p-1}(n) + K_p b_{p-1}(n-1)$
取均方值，可得

$$\begin{aligned}\xi_p &\triangleq E[e_p^2(n)] = E\left\{\left[e_{p-1}(n) + K_p b_{p-1}(n-1)\right]^2\right\} \\ &= E\left[e_{p-1}^2(n)\right] + 2K_p E\left[e_{p-1}(n)b_{p-1}(n-1)\right] \\ &\quad + K_p^2 E\left[b_{p-1}^2(n-1)\right]\end{aligned}$$

- 如果输入信号是平稳的，那么预测误差也是平稳的，可以证明

$$E[e_p^2(n)] = E[b_p^2(n)] = E[b_p^2(n-1)] = \xi_p$$

➤ 则前向均方误差可写成


$$\xi_p = \xi_{p-1}(K_p^2 + 1) + 2K_p\Delta_p$$

其中

$$\Delta_p \triangleq E[e_{p-1}(n)b_{p-1}(n-1)]$$

对前向均方误差求导，可得

$$\frac{\partial \xi_p}{\partial K_p} = 2K_p\xi_{p-1} + 2\Delta_p, \quad p \in \{1, 2, \dots, P\}$$


$$\text{当 } p=1 \text{ 时, } \quad \frac{\partial \xi_1}{\partial K_1} = 2K_1 \xi_0 + 2\Delta_1$$

$$\text{当 } p=2 \text{ 时, } \quad \frac{\partial \xi_2}{\partial K_2} = 2K_2 \xi_1 + 2\Delta_2$$

$$\vdots$$

$$\text{当 } p=P \text{ 时, } \quad \frac{\partial \xi_P}{\partial K_P} = 2K_P \xi_{P-1} + 2\Delta_P$$

$$\text{其中 } \xi_0 = E[u^2(n)], \quad \Delta_1 = E[u(n)u(n-1)]$$

令导数为0，即 $\frac{\partial \xi_1}{\partial K_1} = 2K_1\xi_0 + 2\Delta_1 = 0$

$$\frac{\partial \xi_2}{\partial K_2} = 2K_2\xi_1 + 2\Delta_2 = 0$$

\vdots

$$\frac{\partial \xi_P}{\partial K_P} = 2K_P\xi_{P-1} + 2\Delta_P = 0$$

可得最优的反射系数

$$K_p^o = -\frac{\Delta_p}{\xi_{p-1}} = -\frac{E[e_{p-1}(n)b_{p-1}(n-1)]}{E[e_{p-1}^2(n)]}, \quad p \in \{1, 2, \dots, P\}$$

➤ 递推迭代式

根据最快下降法，每个反射系数的更新公式可写成

$$K_p(n) = K_p(n-1) - \frac{\mu_p}{2} \frac{\partial \xi_p(n-1)}{\partial K_p(n-1)}, \quad p \in \{1, 2, \dots, P\}$$

式中， μ_p 为第 p 级的步长(或称为增益)。

容易求得导数

$$\begin{aligned}\frac{\partial \xi_p(n-1)}{\partial K_p(n-1)} &= \frac{\partial e_p^2(n-1)}{\partial K_p(n-1)} = 2e_p(n-1) \frac{\partial e_p(n-1)}{\partial K_p(n-1)} \\ &= -2e_p(n-1)b_{p-1}(n-2)\end{aligned}$$

将上式代入最速下降公式，可得


$$K_p(n) = K_p(n-1) - \mu_p e_p(n-1)b_{p-1}(n-2)$$

步长满足如下条件

$$0 < \mu_p < \frac{1}{\xi_{p-1}}$$



§ 4.5 RLS自适应滤波算法

- 
- 无论是LMS横向或格型自适应滤波器，在本质上，其收敛速度还是比较慢。
 - 为了解决这一问题，可以采用**递推最小二乘（RLS）**自适应滤波器。
 - **递推最小二乘（RLS）**自适应滤波器的理论基础，是著名的最小二乘法。

- 横向自适应滤波器的输出误差为

$$e(n) = d(n) - \mathbf{w}^T(n) \mathbf{u}(n)$$

- 建立代价函数

$$\varepsilon(n, \mathbf{w}) = \sum_{i=1}^n \lambda^{n-i} |e(i)|^2$$

- 求使得上述代价函数最小的权值向量

$$\mathbf{w}(n) = [w_0(n), w_1(n), \dots, w_{M-1}(n)]^T$$

► 为了使 $\varepsilon(n, \mathbf{w}) = \sum_{i=1}^n \lambda^{n-i} |e(i)|^2$ 最小化，可以令

$$\frac{\partial \varepsilon(n, \mathbf{w})}{\partial \mathbf{w}} = 0, \text{ 即有}$$

$$\begin{aligned} \frac{\partial \varepsilon(\mathbf{w}(n))}{\partial \mathbf{w}(n)} &= \frac{\partial}{\partial \mathbf{w}(n)} \sum_{i=1}^n \lambda^{n-i} [d(i) - \mathbf{w}^T(n) \mathbf{u}(i)]^2 \\ &= -2 \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) [d(i) - \mathbf{w}^T(n) \mathbf{u}(i)] = 0 \\ &= -2 \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) [d(i) - \mathbf{u}^T(i) \mathbf{w}(n)] = 0 \end{aligned}$$

➤ 上式可以转化为

$$\sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) \mathbf{u}^T(i) \mathbf{w}(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) d(i)$$

➤ 若令 $\mathbf{R}(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) \mathbf{u}^T(i)$

$$\mathbf{U}(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) d(i)$$

➤ 则有 $\mathbf{R}(n) \mathbf{w}(n) = \mathbf{U}(n)$

➤ 若 $\mathbf{R}(n)$ 为非奇异矩阵，则可求得最优解为

$$\mathbf{w}(n) = \mathbf{R}^{-1}(n) \mathbf{U}(n)$$

➤ 解 $\mathbf{w}(n) = \mathbf{R}^{-1}(n)\mathbf{U}(n)$ 为滤波器系数的维纳解。
下面，来推导其迭代解。

➤ 利用 $e(n) = d(n) - \mathbf{w}^T(n-1)\mathbf{u}(n)$ ，可得

$$\begin{aligned}\mathbf{U}(n) &= \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) [\mathbf{w}^T(i-1)\mathbf{u}(i) + e(i)] \\ &= \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) [\mathbf{u}^T(i)\mathbf{w}(i-1) + e(i)] \\ &= \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)\mathbf{u}^T(i)\mathbf{w}(i-1) + \mathbf{u}(i)e(i)]\end{aligned}$$

➤ 将式 $\mathbf{U}(n) = \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)\mathbf{u}^T(i)\mathbf{w}(i-1) + \mathbf{u}(i)e(i)]$

代入 $\mathbf{w}(n) = \mathbf{R}^{-1}(n)\mathbf{U}(n)$, 可得

$$\begin{aligned}\mathbf{w}(n) &= \mathbf{R}^{-1}(n) \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)\mathbf{u}^T(i)\mathbf{w}(i-1)] \\ &\quad + \mathbf{R}^{-1}(n) \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)e(i)]\end{aligned}$$

➤ 令 $\mathbf{w}_1(n) = \mathbf{R}^{-1}(n) \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)\mathbf{u}^T(i)\mathbf{w}(i-1)]$

$$\mathbf{w}_2(n) = \mathbf{R}^{-1}(n) \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)e(i)]$$

前述迭代式可简写为 $\mathbf{w}(n) = \mathbf{w}_1(n) + \mathbf{w}_2(n)$ 。

➤ 假设自适应滤波器在 M 个时刻变化不大，即有

$$\mathbf{w}(0) = \mathbf{w}(1) = \cdots = \mathbf{w}(n-1)$$

则可得

$$\begin{aligned}\mathbf{w}_1(n) &= \mathbf{R}^{-1}(n) \left\{ \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i) \mathbf{u}^T(i)] \right\} \mathbf{w}(n-1) \\ &= \mathbf{R}^{-1}(n) \mathbf{R}(n) \mathbf{w}(n-1) \\ &= \mathbf{w}(n-1)\end{aligned}$$

➤ 为了简化 $\mathbf{w}_2(n) = \mathbf{R}^{-1}(n) \sum_{i=1}^n \lambda^{n-i} [\mathbf{u}(i)e(i)]$ ，可以认为遗忘因子 $\lambda = 0$ ，这相当于只记住本时刻的结果，而将以前各时刻的结果全部遗忘。

➤ 采用上述假设之后，可得

$$\mathbf{w}_2(n) = \mathbf{R}^{-1}(n) \mathbf{u}(n)e(n)$$

➤ 将简化后的 $\mathbf{w}_1(n)$ 和 $\mathbf{w}_2(n)$ 代入原递推式，可得

$$\mathbf{w}(n) = \mathbf{w}(n-1) + \mathbf{R}^{-1}(n) \mathbf{u}(n)e(n)$$

➤ 递推式 $\mathbf{w}(n) = \mathbf{w}(n-1) + \mathbf{R}^{-1}(n)\mathbf{u}(n)e(n)$ 需要对矩阵 $\mathbf{R}(n)$ 求逆，具有很高的计算量。

➤ 下面介绍一种递推求解 $\mathbf{R}^{-1}(n)$ 的方法：

根据定义，可将 $\mathbf{R}(n)$ 写成

$$\begin{aligned}\mathbf{R}(n) &= \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) \mathbf{u}^T(i) \\ &= \left\{ \sum_{i=1}^{n-1} \lambda^{n-i} \mathbf{u}(i) \mathbf{u}^T(i) \right\} + \lambda^{n-n} \mathbf{u}(n) \mathbf{u}^T(n) \\ &= \mathbf{R}(n-1) + \mathbf{u}(n) \mathbf{u}^T(n)\end{aligned}$$

➤ 矩阵求逆引理

$$(\mathbf{A} + \mathbf{B}\mathbf{C}^T)^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{B}(\mathbf{I} - \mathbf{C}^T\mathbf{A}^{-1}\mathbf{B})^{-1}\mathbf{C}^T\mathbf{A}^{-1}$$

➤ 利用上述矩阵求逆引理，计算 $\mathbf{R}^{-1}(n)$ 的递推式可变为

$$\mathbf{R}^{-1}(n) = \mathbf{R}^{-1}(n-1) - \frac{\mathbf{R}^{-1}(n-1)\mathbf{u}(n)\mathbf{u}^T(n)\mathbf{R}^{-1}(n-1)}{1 + \mathbf{u}^T(n)\mathbf{R}^{-1}(n-1)\mathbf{u}(n)}$$

➤ RLS算法的工作步骤

(1) 初始化: $\mathbf{w}(0) = \mathbf{0}$, $\mathbf{R}(0) = \mathbf{I}$;

(2) 迭代更新: for $n=1$ 到 N

$$e(n) = d(n) - \mathbf{w}^T(n)\mathbf{u}(n)$$

$$\mathbf{R}^{-1}(n) = \mathbf{R}^{-1}(n-1) - \frac{\mathbf{R}^{-1}(n-1)\mathbf{u}(n)\mathbf{u}^T(n)\mathbf{R}^{-1}(n-1)}{1 + \mathbf{u}^T(n)\mathbf{R}^{-1}(n-1)\mathbf{u}(n)}$$

$$\mathbf{w}(n) = \mathbf{w}(n-1) + \mathbf{R}^{-1}(n)\mathbf{u}(n)e(n)$$

➤ RLS算法的改进

移入遗忘因子 λ ，从而在收敛速度和稳态失调之间进行折中：

$$\mathbf{R}^{-1}(n) = \lambda^{-1} \left[\mathbf{R}^{-1}(n-1) - \frac{\lambda^{-1} \mathbf{R}^{-1}(n-1) \mathbf{u}(n) \mathbf{u}^T(n) \mathbf{R}^{-1}(n-1)}{1 + \lambda^{-1} \mathbf{u}^T(n) \mathbf{R}^{-1}(n-1) \mathbf{u}(n)} \right]$$

移入遗忘因子 λ 的取值，通常在0.9—1之间。

➤ RLS算法的改进

移入遗忘因子 λ ，从而在收敛速度和稳态失调之间进行折中：

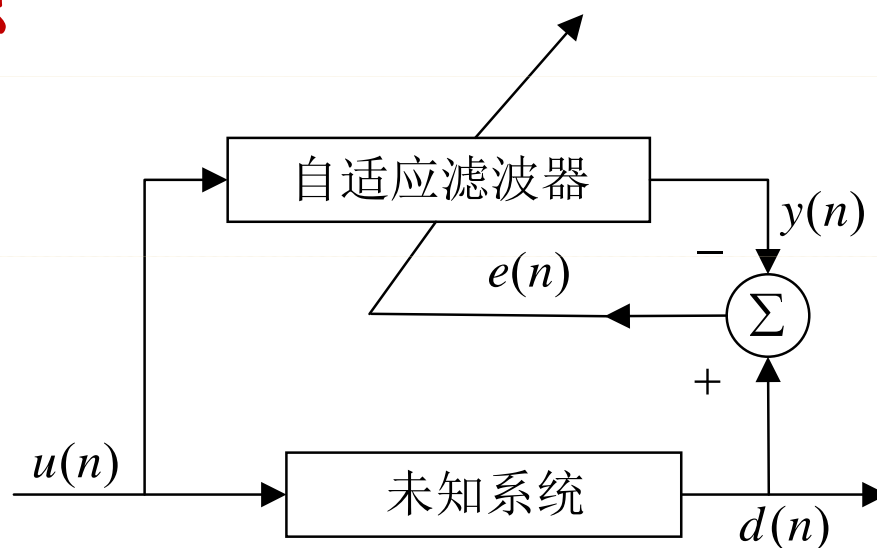
$$\mathbf{R}^{-1}(n) = \lambda^{-1} \left[\mathbf{R}^{-1}(n-1) - \frac{\lambda^{-1} \mathbf{R}^{-1}(n-1) \mathbf{u}(n) \mathbf{u}^T(n) \mathbf{R}^{-1}(n-1)}{1 + \lambda^{-1} \mathbf{u}^T(n) \mathbf{R}^{-1}(n-1) \mathbf{u}(n)} \right]$$

移入遗忘因子 λ 的取值，通常在0.9—1之间。



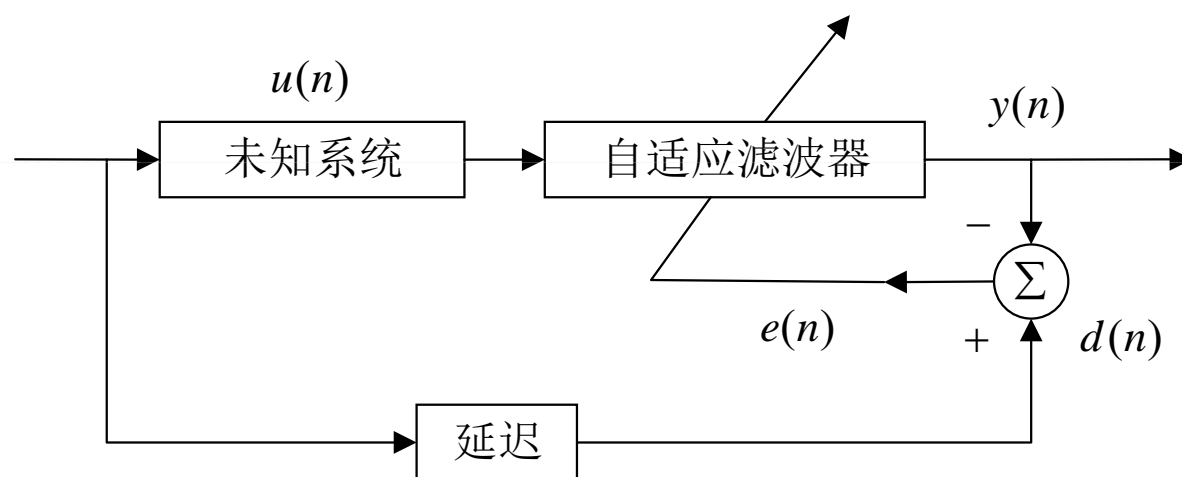
§ 4.6 自适应滤波器的应用

➤ 系统辨识



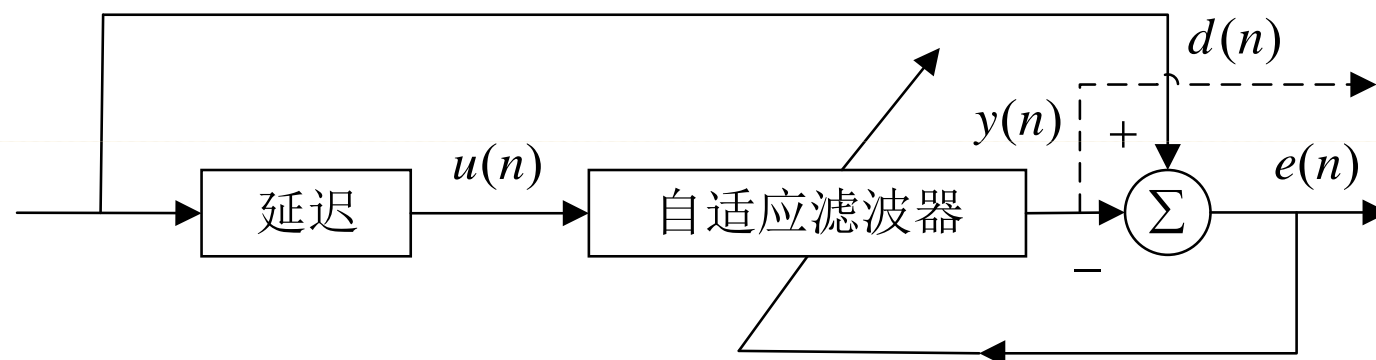
对于系统辨识，自适应滤波器的主要作用是提供逼近未知系统的线性模型。图中 n 代表时刻， $u(n)$ 是系统输入信号，通过未知系统得到期望响应 $d(n)$ ，通过自适应滤波器得到系统输出 $y(n)$ 。将期望响应和系统输出相减可得系统误差 $e(n)$ 。通过将系统误差 $e(n)$ 反馈给自适应滤波器，自适应滤波器可以不断地自适应调节，直到滤波器的参数无限逼近未知系统的参数，最后完成系统辨识。

➤ 逆建模




对于信道均衡，自适应滤波器的作用是提供均衡器的一个模型。图中， $u(n)$ 是经过未知系统后的输入，经过自适应滤波器得到系统输出 $y(n)$ ，系统输入通过延迟器得到含噪的期望输出 $d(n)$ ，用期望输出与系统输出之差 $e(n)$ 反馈调节自适应滤波器，直至自适应滤波器逼近未知系统的逆模型。

➤ 信号预测



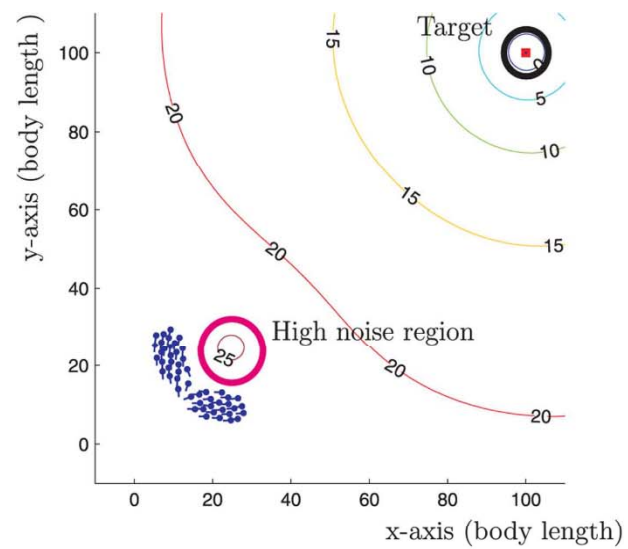
对于信号预测，自适应滤波器的作用就是对随机信号的当前值提供一个最佳的预测。通过延迟器后的系统输入 $u(n)$ 经过自适应滤波器后得到系统输出 $y(n)$ ，当前的信号值 $d(n)$ 作为期望响应，两者之差 $e(n)$ 反馈到自适应滤波器，自适应学习后的系统输出可以作为下个时刻信号值的预测。

➤ 噪声消除

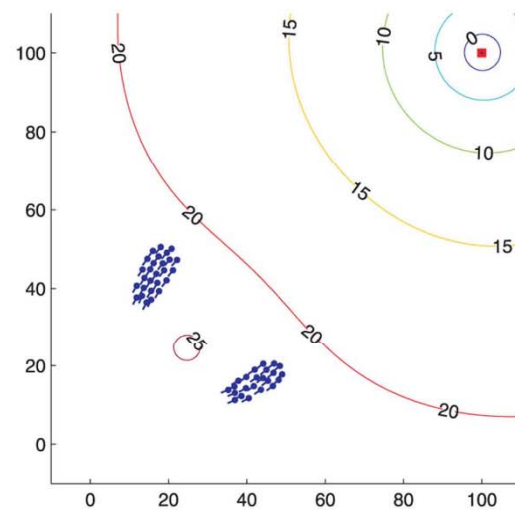


对于噪声消除，自适应滤波器主要作用是消除信号中无用的噪声干扰。图中， $u(n)$ 是系统输入，经过自适应滤波器滤波得到系统输出 $y(n)$ ，此时将给定的期望响应 $d(n)$ 和系统输出相减得到系统误差 $e(n)$ ，自适应滤波器利用系统误差自适应反馈调节，直到系统误差小于预定值，从而达到消除噪声干扰的目的。

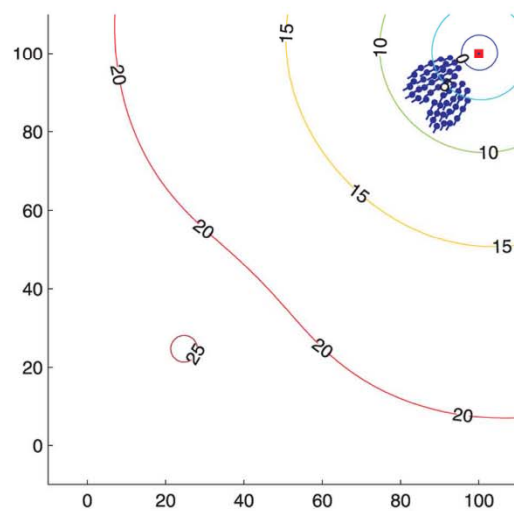
➤ 目标定位与跟踪



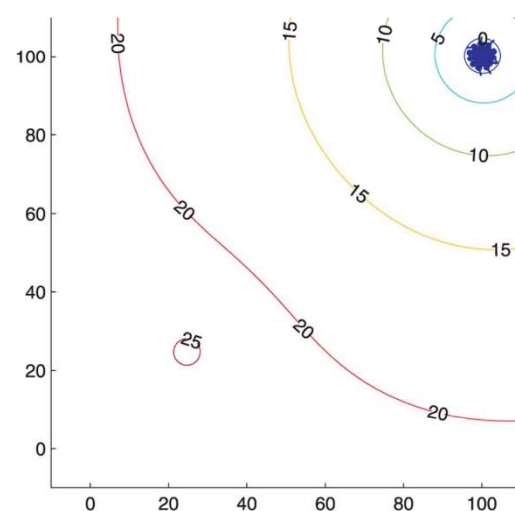
(a)



(b)

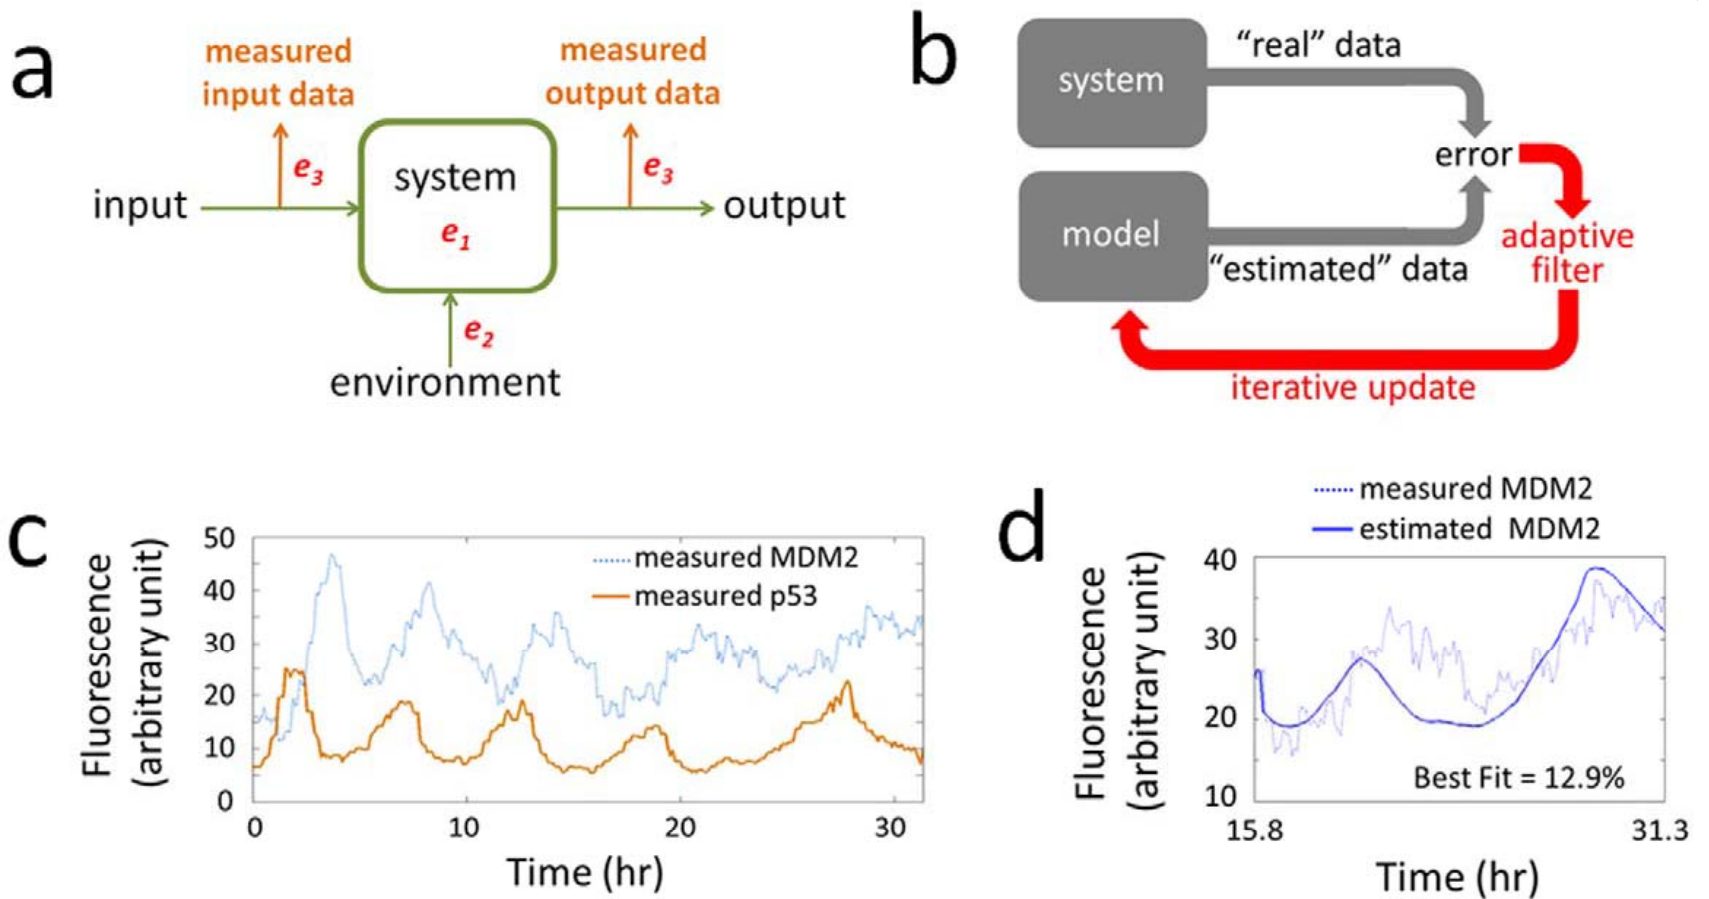


(c)



(d)

➤ 基因网络建模



➤ 动物群体运动建模

