



## 第二章 维纳滤波



## §2.1 线性最优滤波


# 1、传统数字滤波与维纳数字滤波



传统数字滤波框图

已知输入信号  $u(n)$  和滤波器  $w$ ，求输出  $y(n)$

其目的是滤除输入信号  $u(n)$  中的某些频谱




维纳数字滤波框图

$$e(n) = d(n) - y(n)$$


已知输入信号  $u(n)$  和期望响应(参考信号)  $d(n)$ ，使误差信号  $e(n)$  在某种统计意义上最小。

对于一个因果滤波器，其 $n$ 时刻的输出为卷积


$$y(n) = \sum_{k=0}^{\infty} w_k^* u(n-k), n = 0, 1, 2, \dots$$




(a) 脉冲响应



(b) 滤波器输入



(c) 滤波器输入的时间反转和移位型



(d)  $n=3$ 时刻滤波器输出

## 2、代价函数的选择

使  $e(n) = d(n) - y(n)$  在**某种统计意义上**最小，  
需要定义关于  $e(n)$  的代价函数。

估计误差的均方值  $E[|e(n)|^2]$

估计误差绝对值的期望  $E[|e(n)|]$

估计误差绝对值的高阶矩  $E[e^p(n)], p \geq 3$



## §2.2 正交性原理及其推论

## 1、最小均方误差准则

$$J(n) = E[|e(n)|^2] = E[e(n)e^*(n)] \quad (\text{复数情况})$$

$$J(n) = E[|e(n)|^2] = E[e^2(n)] \quad (\text{实数情况})$$

采用均方误差的优点：该代价函数具有唯一的最小值。



## 2、如何求最小值

求函数对所有变量的偏导数，令所有偏导数为0，其对应的变量为多元函数取得最小值的解。

为了方便表示，常将所有的偏导数写成列向量，该列向量称为函数的**梯度**或**共轭梯度**。

因此，令所有偏导数为0，等价于令**梯度**或**共轭梯度**为0。

### 3、正交性原理

设第 $k$ 个滤波器系数可表示为

$$w_k = a_k + jb_k, k = 0, 1, 2, \dots$$

则滤波器系数向量可表示为

$$\mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_{M-1} \\ \vdots \end{bmatrix} = \begin{bmatrix} a_0 + jb_0 \\ a_1 + jb_1 \\ \vdots \\ a_{M-1} + jb_{M-1} \\ \vdots \end{bmatrix}$$

可以定义一个梯度算子  $\nabla = [\nabla_0, \nabla_1, \dots, \nabla_{M-1}]^T$ ，其第  $k$  个元素可以写成实部和虚部的一阶偏微分形式

$$\nabla_k = \frac{\partial}{\partial a_k} + j \frac{\partial}{\partial b_k} \quad k = 0, 1, 2, \dots$$

将算子  $\nabla$  用于代价函数  $J$ ，可得到一个多维复数值梯度向量  $\nabla J$ ，其第  $k$  个元素为

$$\nabla_k J = \frac{\partial J}{\partial a_k} + j \frac{\partial J}{\partial b_k} \quad k = 0, 1, 2, \dots$$

根据代价函数  $J(n) = E[e(n)e^*(n)]$  可得

$$\nabla_k J = E \left[ \frac{\partial e(n)}{\partial a_k} e^*(n) + \frac{\partial e^*(n)}{\partial a_k} e(n) \right. \\ \left. + \frac{\partial e(n)}{\partial b_k} j e^*(n) + \frac{\partial e^*(n)}{\partial b_k} j e(n) \right]$$

$$e(n) = d(n) - y(n) = d(n) - \mathbf{w}^H \mathbf{u}(n)$$

$$= d(n) - \sum_{k=0}^{\infty} w_k^* u(n-k)$$

$$e^*(n) = d^*(n) - \sum_{k=0}^{\infty} w_k u^*(n-k)$$

$$e(n) = d(n) - y(n) = d(n) - \mathbf{w}^H \mathbf{u}(n)$$

$$= d(n) - \sum_{k=0}^{\infty} w_k^* u(n-k)$$

$$e^*(n) = d^*(n) - \sum_{k=0}^{\infty} w_k u^*(n-k)$$

$$\frac{\partial e(n)}{\partial a_k} = -u(n-k), \quad \frac{\partial e^*(n)}{\partial a_k} = -u^*(n-k)$$

$$\frac{\partial e(n)}{\partial b_k} = ju(n-k), \quad \frac{\partial e^*(n)}{\partial b_k} = -ju^*(n-k)$$

将

$$\frac{\partial e(n)}{\partial a_k} = -u(n-k), \quad \frac{\partial e^*(n)}{\partial a_k} = -u^*(n-k)$$

$$\frac{\partial e(n)}{\partial b_k} = ju(n-k), \quad \frac{\partial e^*(n)}{\partial b_k} = -ju^*(n-k)$$

代入

$$\begin{aligned} \nabla_k J = E & \left[ \frac{\partial e(n)}{\partial a_k} e^*(n) + \frac{\partial e^*(n)}{\partial a_k} e(n) \right. \\ & \left. + \frac{\partial e(n)}{\partial b_k} j e^*(n) + \frac{\partial e^*(n)}{\partial b_k} j e(n) \right] \end{aligned}$$

可得  $\nabla_k J = -2E[u(n-k)e^*(n)]$

$$\nabla_k J = -2E[u(n-k)e^*(n)]$$

为了使代价函数 $J$ 达到最小值(即滤波器达到最优), 梯度向量  $\nabla J$  的所有元素必须都等于零:

$$\nabla_k J = 0, \quad k = 0, 1, 2, \dots$$

令滤波器达到最优时的误差为  $e_o(n)$ , 则有

$$E[u(n-k)e_o^*(n)] = 0, \quad k = 0, 1, 2, \dots$$

**正交性原理:** 使代价函数 $J$ 获得最小值的充要条件, 是其对应的估计误差正交于 $n$ 时刻进入期望相应估计的每个输入样值。

## 4、正交性原理推论

根据自适应滤波器的输出，可得


$$\begin{aligned} E[y(n)e^*(n)] &= E\left[\sum_{k=0}^{\infty} w_k^* u(n-k)e^*(n)\right] \\ &= \sum_{k=0}^{\infty} w_k^* E[u(n-k)e^*(n)] \end{aligned}$$

根据正交性原理

$$E[u(n-k)e_o^*(n)] = 0, \quad k = 0, 1, 2, \dots$$

可推得  $E[y_o(n)e_o^*(n)] = 0$





## §2.3 最小均方误差

令  $\hat{d}(n | \mathbf{U}_n)$  表示均方意义下最优的期望响应的估值，即

$$y_o(n) = \hat{d}(n | \mathbf{U}_n)$$

其中， $\mathbf{U}_n$  表示输入信号  $u(n)$  直到时刻  $n$  的样值张成的空间。当滤波器达到最优时，估计误差可写为

$$e_o(n) = d(n) - y_o(n) = d(n) - \hat{d}(n | \mathbf{U}_n)$$

对上式进行整理，可得

$$d(n) = \hat{d}(n | \mathbf{U}_n) + e_o(n)$$

令  $J_{\min} = E[|e_o(n)|^2]$  表示最小均方误差。

对式  $d(n) = \hat{d}(n | \mathbf{U}_n) + e_o(n)$  两边取期望，并利用正交性原理的推论，可得

$$\sigma_d^2 = \sigma_{\hat{d}}^2 + J_{\min}$$

上式可改写为

$$J_{\min} = \sigma_d^2 - \sigma_{\hat{d}}^2$$

将式  $J_{\min} = \sigma_d^2 - \sigma_{\hat{d}}^2$  两边同除以  $\sigma_d^2$ , 可得归一化均方误差

$$\varepsilon = \frac{J_{\min}}{\sigma_d^2} = 1 - \frac{\sigma_{\hat{d}}^2}{\sigma_d^2}$$


归一化均方误差  $\varepsilon$  :

((1))非负

((2))比例满足范围  $0 \leq \varepsilon \leq 1$ 。

当  $\varepsilon = 0$  时,  $\hat{d}(n | \mathbf{U}_n)$  与  $d(n)$  完全一致;

当  $\varepsilon = 1$  时, 二者很不一致, 对应最差的情况。



## §2.4 维纳-霍夫方程

# 1、一般情况下的维纳-霍夫方程

根据最优情况下误差信号的定义

$$e_o(n) = d(n) - y_o(n) = d(n) - \sum_{i=0}^{\infty} w_{o,i}^* u(n-i)$$

和正交性原理

$$E[u(n-k)e_o^*(n)] = 0, \quad k = 0, 1, 2, \dots$$

可得

$$\sum_{i=0}^{\infty} w_{o,i} E[u(n-k)u^*(n-i)] = E[u(n-k)d^*(n)]$$

$$k = 0, 1, 2, \dots$$

$$\sum_{i=0}^{\infty} w_{o,i} E[u(n-k)u^*(n-i)] = E[u(n-k)d^*(n)], k = 0, 1, 2, \dots$$

第一个期望  $E[u(n-k)u^*(n-i)]$ ：等于相隔  $i-k$  个延迟的输入信号自相关函数，即

$$r(i-k) = E[u(n-k)u^*(n-i)]$$

第二个期望  $E[u(n-k)d^*(n)]$ ：等于输入信号  $u(n-k)$  与期望响应  $d(n)$  相隔  $-k$  个延迟的互相关，即

$$p(-k) = E[u(n-k)d^*(n)]$$

将式  $r(i-k) = E[u(n-k)u^*(n-i)]$

$$p(-k) = E[u(n-k)d^*(n)]$$

代入

$$\sum_{i=0}^{\infty} w_{o,i} E[u(n-k)u^*(n-i)] = E[u(n-k)d^*(n)],$$

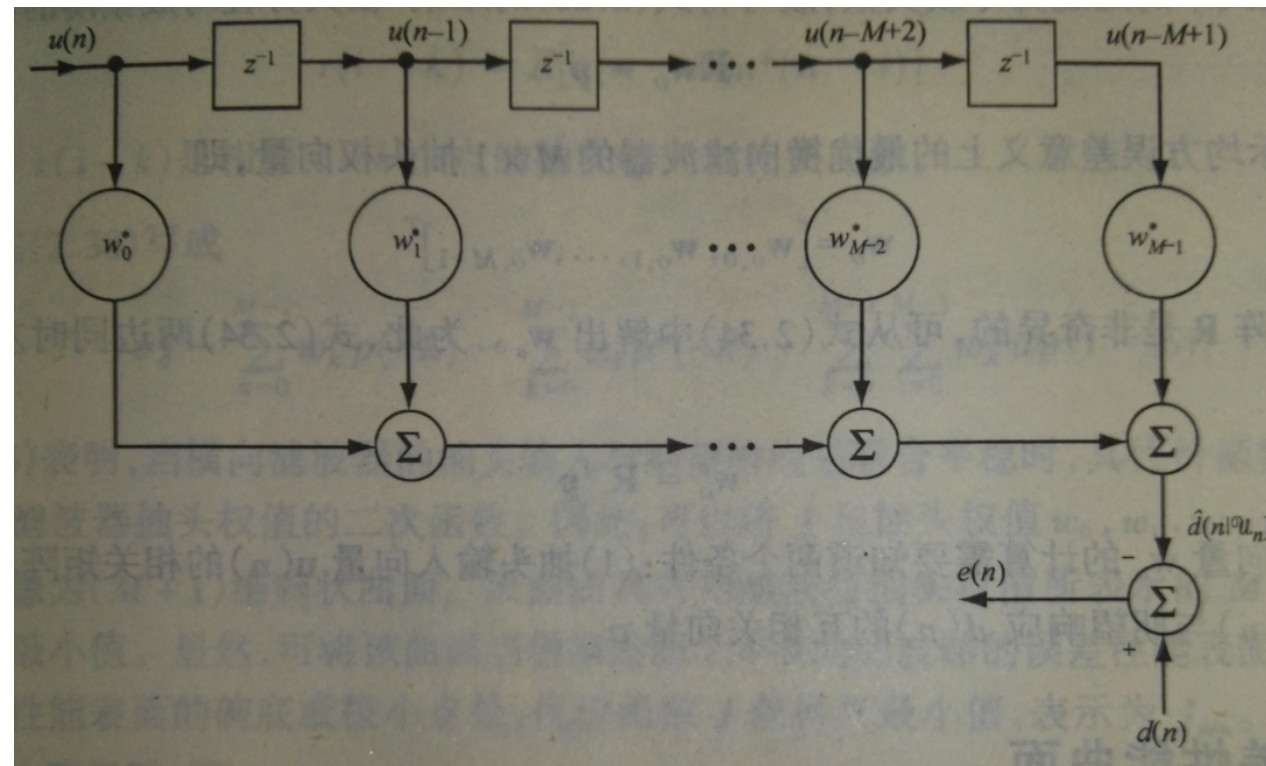
$$k = 0, 1, 2, \dots$$

可得维纳霍-夫方程

$$\sum_{i=0}^{\infty} w_{o,i} r(i-k) = p(-k), \quad k = 0, 1, 2, \dots$$



## 2、线性横向滤波器的维纳-霍夫方程



$$\sum_{i=0}^{\infty} w_{o,i} \kappa(i-k) = p(-k), \quad k = 0, 1, 2, \dots \quad \text{简化为}$$

$$\sum_{i=0}^{M-1} w_{o,i} \kappa(i-k) = p(-k), \quad k = 0, 1, \dots, M-1$$

对于横向滤波器，第 $n$ 时刻的输入向量可表示为

$$\mathbf{u}(n) = [u(n), u(n-1), \dots, u(n-M+1)]^T$$

则其相关矩阵为

$$\begin{aligned} \mathbf{R} &= E[\mathbf{u}(n)\mathbf{u}^H(n)] \\ &= \begin{bmatrix} r(0) & r(1) & \dots & r(M-1) \\ r^*(1) & r(0) & \dots & r(M-2) \\ \dots & \dots & \dots & \dots \\ r^*(M-1) & r^*(M-2) & \dots & r(0) \end{bmatrix} \end{aligned}$$

将滤波器的输入向量与期望响应的互相关向量记为

$$\mathbf{p} = E[\mathbf{u}(n)d^*(n)]$$

则维纳-霍夫方程可写成矩阵形式：

$$\mathbf{R}\mathbf{w}_o = \mathbf{p}$$

其中， $\mathbf{w}_o = [w_{o,0}, w_{o,1}, \dots, w_{o,M-1}]^T$

如果相关矩阵是非奇异的，则可解出令代价函数最小的最优权值向量，即

$$\mathbf{w}_o = \mathbf{R}^{-1}\mathbf{p}$$